

Canal de voz del agente de Logística Demo S.A.

Workflow: **Checkpoint 6 - Canal de Voz (Telegram + Whisper + ElevenLabs)**. El cliente le habla al bot de Telegram con una nota de voz; Whisper la transcribe, el AI Agent (Tools Agent) responde consultando el manual de políticas del Módulo 5 (RAG) y ElevenLabs convierte la respuesta en audio, que vuelve al mismo chat.

Recorrido: Telegram Trigger → Descargar nota de voz → Renombrar a .ogg → Whisper (STT) → ¿Transcripción válida? → Purgar audio del cliente → AI Agent → Texto para voz (≤ 200) → Parámetros de voz → ElevenLabs (TTS) → Enviar nota de voz → Purgar audio generado




Figura 1. Ejecución de producción exitosa (8/10, 19:49). Todos los nodos del camino feliz en verde. Las ramas Error de la descarga y de Whisper, y la rama false del IF, van a "Contingencia - pedir repetir"; la rama Error de ElevenLabs va a "Fallback texto (TTS caído)".

Requisito de la consigna	Dónde se cumple
Trigger de mensajería que recibe voz	Telegram Trigger (updates: message) + Descargar nota de voz (Telegram, Get a file, download = true)
Whisper inmediatamente después del trigger, binario data, idioma es	Oídos del agente - Whisper (STT): campo file = binario data, language = es (Figura 2)
Texto de Whisper al AI Agent (Tools Agent)	Cerebro - AI Agent (voz) recibe texto_cliente (Figura 3)
Regla de máximo 200 caracteres	Sección CONTENCIÓN FINANCIERA del System Prompt + nodo Texto para voz (≤ 200)
ElevenLabs Multilingual con Stability / Clarity	Parámetros de voz (marca) + Voz del agente - ElevenLabs (TTS) (Figura 5)
Envío del audio por Telegram	Enviar nota de voz (Telegram): Send Audio con el binario data de ElevenLabs (Figura 6)
Contingencia IF para transcripciones corruptas o vacías	¿Transcripción válida? + Contingencia - pedir repetir (Figuras 7 y 8)
Destrucción del audio binario	Purgar audio del cliente, Purgar audio generado y Settings sin guardar ejecuciones (Figura 9)

1. Oídos del agente: Whisper (STT)




Figura 2. Nodo Oídos del agente - Whisper (STT). Multipart al endpoint de transcripción de Groq: file = n8n Binary File tomado del campo data, model = whisper-large-v3, language = es (además temperature = 0 y response_format = json).

Por qué hay dos nodos entre el trigger y Whisper: el Telegram Trigger solo recibe el file_id de la nota de voz, no el audio. "Descargar nota de voz" (Get a file) baja el binario al campo data, y "Renombrar a .ogg" cambia la extensión .oga que usa Telegram por .ogg, porque la API rechaza .oga aunque el contenido sea el mismo (Ogg/Opus). Ninguno de los dos procesa el contenido: Whisper sigue siendo el primer nodo que trabaja con el audio.

Desvío respecto del nodo sugerido: se usa Whisper large-v3 servido por Groq vía HTTP Request (API compatible con OpenAI) en lugar del nodo OpenAI, porque el proyecto ya usa Groq como proveedor y su capa gratuita cubre la transcripción. El modelo y los parámetros son los mismos.

2. Cerebro: AI Agent con límite de 200 caracteres




Figura 3. System Prompt del AI Agent (voz). Secciones ROL, CONOCIMIENTO (RAG), CONTENCIÓN FINANCIERA (OBLIGATORIA): "Limitá SIEMPRE tu respuesta a un máximo de 200 caracteres, espacios incluidos", y DISEÑO PARA VOZ (VUI).

Doble control de costo: el prompt pide 200 caracteres como máximo y el nodo Texto para voz (≤ 200) lo garantiza aunque el modelo se pase: quita los símbolos de markdown y recorta en el último espacio antes del carácter 200. Como ElevenLabs cobra por carácter, cada respuesta cuesta como máximo 200 créditos.

Diseño para voz: frases cortas, sin listas ni emojis ni citas entre paréntesis, y los números escritos como se dicen ("entre 2 y 8 grados"), para que el audio suene natural.




Figura 4. Herramienta buscar_manual_politicas: descripción visible para el modelo y sub-workflow "Checkpoint 5 - Base de Conocimiento RAG" (Top-K 3, Minimum Score 0,68) elegido desde la lista.

3. Voz del agente: ElevenLabs (TTS)




Figura 5 (izq.). Parámetros de voz (marca): voz George (voice_id JBFqnCBsd6RMkjVDRZzb), modelo eleven_multilingual_v2, stability 0,65, clarity_similarity 0,8, style 0. Figura 5b (der.). API key "n8n agente voz Telegram" en ElevenLabs: clave restringida, límite de 2.000 créditos y acceso solo a De texto a voz.

Parámetro	Valor	Justificación
Modelo	eleven_multilingua l_v2	Pronunciación nativa en español, incluidos números y nombres de ciudades argentinas.
Stability	0,65	Tono parejo y profesional de atención al cliente, sin cambios de emoción entre respuestas.
Clarity + Similarity	0,8	Voz nítida y fiel a la original sin los artefactos que aparecen cerca de 1.
Style	0	Sin exageración expresiva; además reduce la latencia.
Formato de salida	mp3_44100_64	Archivo liviano (20 a 40 KB por respuesta) que Telegram reproduce directo.

Nodo Voz del agente - ElevenLabs (TTS): HTTP Request POST a `api.elevenlabs.io/v1/text-to-speech/{voice_id}`, autenticado con una credencial Header Auth (xi-api-key). El body envía text, model_id y voice_settings (stability, similarity_boost, style) tomados del nodo anterior, y la respuesta se guarda como archivo en el binario data. Se usa HTTP Request en lugar del nodo de comunidad para no depender de un paquete externo en n8n self-hosted.





Figura 5c (izq.). Nodo Voz del agente - ElevenLabs (TTS): POST a /v1/text-to-speech/{{ \$json.voice_id }} con salida mp3_44100_64 y credencial Header Auth "ElevenLabs". Figura 5d (der.). Body JSON con text, model_id y voice_settings (stability, similarity_boost, style); la respuesta se guarda como File en el campo data.

Mínimo privilegio: la API key de ElevenLabs está restringida: solo tiene acceso a "De texto a voz" (todos los demás endpoints en "Sin acceso") y un tope de 2.000 créditos por período. Si se filtrara, no permitiría clonar voces, transcribir audios ni gastar más que ese tope.

4. Envío del audio por Telegram




Figura 6. Enviar nota de voz (Telegram): operación Send Audio, Binary File activado, Input Binary Field = data (el MP3 que devolvió ElevenLabs), mismo Chat ID del cliente.

Se usa Send Audio porque ElevenLabs devuelve MP3; Send Voice exige Ogg/Opus. El cliente recibe un audio titulado "Logística Demo · Atención al Cliente" que se reproduce en el chat (Figura 10). Si ElevenLabs falla (sin créditos, caída del servicio), la rama Error envía la misma respuesta en texto con "Fallback texto (TTS caído)": el cliente nunca se queda sin respuesta.

5. Contingencia: audio corrupto o transcripción vacía




Figura 7. IF ¿Transcripción válida?: la transcripción (sin espacios) debe tener 4 caracteres o más Y la nota de voz debe durar 1 segundo o más. Si no, sale por false.

Situación	Qué hace el flujo
Transcripción vacía, ruido o audio de menos de 1 s	IF → false → Contingencia - pedir repetir. No pasa por la IA ni por ElevenLabs (costo cero).
Audio corrupto (Whisper devuelve error)	Rama Error de Whisper → Contingencia - pedir repetir.
Mensaje que no es audio (texto, foto)	Rama Error de Descargar nota de voz → Contingencia - pedir repetir.
Transcripción válida pero incomprensible	El agente pide que repita en una sola frase (regla de DISEÑO PARA VOZ, Figura 8).
ElevenLabs no responde	Fallback texto (TTS caído) envía la respuesta escrita.

Mensaje de contingencia: "No pude entender bien el audio. ¿Me lo puede repetir en una nota de voz corta, sin ruido de fondo?"




Figura 8. Audio breve sin una consulta clara (19:57): el agente responde "Disculpe, ¿podría repetir su consulta en una sola frase, por favor?" y la respuesta llega en audio.

6. Compliance: destrucción del audio binario

Workflow settings for Checkpoint 6 - Canal de Voz (Telegram + Whisper + ElevenLabs) (#4a8UnHuSekZNEKij)	
Execution Logic	v1 (recommended)
Error Workflow (to notify when this one errors)	- No Workflow -
Timezone	Default - America/New York
Save failed production executions	Do not save
Save successful production executions	Do not save
Save manual executions	Default - Save
Save execution progress	Default - Do not save
Redact production execution data Upgrade	Default - Do not redact
Redact manual execution data Upgrade	Default - Do not redact
Timeout Workflow	☐
Estimated time saved	Fixed
	1 Minutes per production execution

[Save](#)

Figura 9. Settings del workflow: Save failed production executions y Save successful production executions en "Do not save".

- **Memoria volátil:** n8n corre con `N8N_DEFAULT_BINARY_DATA_MODE=default`, así que el audio vive solo en la memoria de la ejecución y no se escribe en disco.
- **Purgar audio del cliente:** apenas Whisper devuelve el texto, este Set conserva solo `chat_id`, nombre y `texto_cliente`, con `Include Binary` desactivado. Desde ahí en adelante, la voz del cliente ya no viaja por el flujo.
- **Purgar audio generado:** después del envío, el MP3 de ElevenLabs se descarta de la misma forma.
- **Sin historial:** las ejecuciones de producción no se guardan, ni las exitosas ni las fallidas, así que no queda ningún audio en la base de datos de n8n al terminar el flujo. Durante las pruebas se activó el guardado de forma temporal para depurar, y se volvió a "Do not save" al terminar.
- **Secretos:** las keys de Groq, ElevenLabs y Telegram viven en credenciales de n8n; el JSON exportado solo guarda sus referencias.

7. Pruebas en Telegram




Figura 10. Chat con el bot Logística Demo Soporte: notas de voz del cliente (violeta) y respuestas en audio del agente; al final, un mensaje de texto sale por la contingencia.

Prueba	Resultado del agente	Veredicto
Voz: "¿A cuántos grados llevan la fruta?"	"Transportamos la fruta en rango refrigerado, entre 2 y 8 grados Celsius." (en audio)	✓ Correcto, dato del manual (sección 5)
Voz: "¿Cuánto tarda un envío a Mendoza?"	"El envío a Mendoza tarda entre 72 y 96 horas hábiles." (en audio)	✓ Correcto, dato del manual (sección 4, zona Cuyo)
Voz: "¿Cuánto cuesta un viaje a Córdoba?"	"No sé. Le puedo derivar a un asesor para que le informe el precio."	✓ Correcto: el manual no tiene precios
Audio breve sin consulta clara	"Disculpe, ¿podría repetir su consulta en una sola frase, por favor?" (en audio)	✓ Pide repetir
Mensaje de texto "Hola" (no es audio)	"No pude entender bien el audio. ¿Me lo puede repetir...?"	✓ Contingencia, sin costo de IA ni de TTS




Figura 11. Ejecución de la prueba de Mendoza (20:07): recorrido completo hasta Enviar nota de voz y respuesta del agente "El envío a Mendoza tarda entre 72 y 96 horas hábiles."

Problemas encontrados y cómo se resolvieron

Problema	Solución
Whisper: "expects binary file data"	El Telegram Trigger no descarga el audio; se agregó Descargar nota de voz (Get a file).
Groq rechaza el archivo .oga	Nodo Renombrar a .ogg (mismo contenido Ogg/Opus, extensión aceptada).
ElevenLabs 401 invalid_authorization_header	Se corrigió la credencial Header Auth (name xi-api-key, solo la key en value).
Agent stopped due to max iterations	La herramienta apuntaba a un ID de workflow inexistente; se eligió el sub-workflow desde la lista y se volvió a cargar el manual (el vector store en memoria se borra al reiniciar n8n).
Respuesta en texto en lugar de audio	Faltaba el voice_id; se configuró una voz predeterminada de ElevenLabs.