

Auditoría de calidad del agente de voz: Juez LLM, test A/B y proyección de costos

Agente supervisado: el canal de voz del proyecto integrador (Módulo 6: Telegram + Whisper + RAG del Módulo 5 + ElevenLabs), con memoria y contexto de Airtable (Módulo 3). **Lo que suma este checkpoint:** un sub-workflow Juez con salida JSON forzada, un Switch de tres rutas (Aceptar / Corregir con Self-Healing / Escalar con Human-in-the-loop), el registro de cada veredicto en Airtable y un test A/B de 10 corridas.

Bloque del checklist	Dónde está
Supervisor + rúbrica del Juez en JSON (Arquitectura 30 % + Branching y umbrales 30 %)	Sección 1: diagrama, capturas del sub-workflow y del Switch, prompt y esquema transcritos, evidencia de las 3 rutas en producción
Matriz A/B de 10 corridas (20 %)	Sección 2: 5 corridas de la Arquitectura A y 5 de la B, con precisión y costo por corrida
Dashboard + proyección (20 %)	Sección 3: precisión media, categorías de error, costo proyectado a 1.000 ejecuciones y recomendación

1. Supervisor + rúbrica del Juez en JSON

1.1 Qué recibe el Juez

El nodo "Preparar evaluación" arma el objeto JSON que exige la consigna y lo pasa al sub-workflow Juez con Execute Workflow (Wait For Sub-Workflow Completion activado):

<pre>{ "query": "¿Cuánto tarda un camión hasta Bariloche?", (transcripta por Whisper) "contexto_airtable": "Sin historial previo", Sesiones (Airtable) "fragmentos_manual": "4. Plazos de entrega ... Patagonia Neuquén, Río Negro ... 96 a 120 horas hábiles", "respuesta": "El plazo de entrega a Bariloche es entre 96 y 120 horas hábiles.", "intento": 0, "arquitectura": "A (producción)" }</pre>	← query original del usuario ← Resumen Consolidado de la tabla ← respuesta propuesta
---	---

Además del contexto de Airtable, el Juez recibe los fragmentos del manual que el agente recuperó (de sus intermediateSteps). Sin ellos no podría verificar la exactitud factual de una respuesta RAG.

1.2 Diagrama del flujo de supervisión




Figura 1. Flujo de supervisión. El veredicto se registra siempre en Airtable. El Switch tiene tres salidas: ACEPTADO (exactitud ≥ 4) envía el audio, CORREGIR devuelve la crítica al agente (máximo 2 reintentos) y RECHAZADO (fallback, incluida la falla del Juez) congela la respuesta y la escala a Slack con los botones Aprobar / Editar.

1.3 El supervisor en n8n




Figura 2. Ejecución 327 en producción, ruta ACEPTADO: Cerebro → Preparar evaluación → Evaluar respuesta (Juez) → Ruta del veredicto → Texto para voz → ElevenLabs → Telegram. En paralelo, Fila de auditoría → Registrar veredicto (Airtable). La rama de Slack queda sin ejecutar.




Figura 3. Ejecución 336, ruta CORREGIR (Self-Healing): el Juez devolvió CORREGIR, "Reintento con la crítica" volvió a llamar al agente con la crítica y la segunda respuesta salió por ACEPTADO hacia el audio.

1.4 Sub-workflow Juez




Figura 4. Sub-workflow "Checkpoint 8 - Juez (AI-as-a-Judge)": Basic LLM Chain con Groq gpt-oss-120b (temperatura 0) y Structured Output Parser. La salida de error del LLM arma un veredicto RECHAZADO (categoría ERROR_JUEZ): el Switch nunca recibe texto libre.

1.5 Rúbrica del Juez: prompt transcripto

```
# ROL
Sos el Juez de calidad (QA) de las respuestas del asistente de Atención al Cliente de Logística Demo S.A. No le respondés al cliente: evaluás la respuesta propuesta y devolvés solo el JSON del esquema.

# QUÉ RECIBÍS
Un JSON con: query_original (lo que preguntó el cliente), contexto_airtable (memoria del cliente guardada en Airtable), fragmentos_manual (lo que el agente recuperó del Manual MAN-SC-001) y respuesta_propuesta.

# FUENTE DE VERDAD
Solo fragmentos_manual y contexto_airtable. No uses conocimiento propio para dar por buena una respuesta: si un dato de la respuesta no está en esas fuentes, es DATO_NO_RESPALDADO aunque sea cierto en el mundo real.
Verificación obligatoria antes de puntuar:
- Lugares: una localidad está respaldada SOLO si su nombre aparece escrito en los fragmentos. Que pertenezca a una provincia o zona de la tabla NO alcanza: eso es una inferencia con conocimiento externo. Ejemplo: si preguntan por Rafaela, los fragmentos nombran Santa Fe pero no Rafaela, y la respuesta da el plazo de la zona Centro, entonces es DATO_NO_RESPALDADO, exactitud 2 y CORREGIR. Lo correcto es "No sé" más la derivación a un asesor.
- Cálculos: una cuenta simple hecha con un dato de los fragmentos y un dato que dio el cliente (por ejemplo, aplicar el porcentaje del seguro al valor de la carga) SÍ está respaldada, aunque el resultado no aparezca escrito. Verificá que la cuenta esté bien hecha.

# RÚBRICA: exactitud_factual (entero de 1 a 5)
5 = Todos los datos coinciden con los fragmentos y responde lo que se preguntó. Si el dato no está en los fragmentos y la respuesta dice "No sé" y deriva a un asesor, también es 5.
4 = Correcta y respaldada, con una omisión menor (un matiz o la derivación) que no induce a error.
3 = Incompleta o ambigua, o no respeta el formato de voz (más de 200 caracteres, listas, markdown o emojis).
2 = Incluye al menos un dato no respaldado o inferido (por ejemplo, ubicar una ciudad en una zona que los fragmentos no mencionan).
1 = Contradice el manual; promete precios, descuentos, compensaciones o plazos que no figuran; responde fuera del ámbito de la empresa; o está vacía o es un mensaje de error.

# estado_veredicto
ACEPTADO = exactitud 4 o 5.
CORREGIR = exactitud 2 o 3 y el error se arregla reescribiendo con los fragmentos.
RECHAZADO = exactitud 1, o cualquier promesa de dinero, precio o compensación, tema legal o datos de otro cliente.

# categoria_error (una sola: la más grave)
NINGUNO · DATO_INCORRECTO · DATO_NO_RESPALDADO · OMISION · FORMATO_VOZ · PROMESA_RIESGOSA · FUERA_DE_AMBITO

# critica
Una o dos frases concretas para que el agente corrija: qué está mal y qué dice el fragmento. Si el veredicto es ACEPTADO, escribí "Sin observaciones".

Devolvé solo el JSON, sin texto adicional.
```




Figura 5. Prompt del nodo "Juez - LLM con JSON Schema" (versión 3, después de la calibración del punto 1.9).

1.6 Esquema JSON forzado (Structured Outputs)

```
{
  "type": "object",
  "properties": {
    "exactitud_factual": {
      "type": "integer",
      "minimum": 1,
      "maximum": 5,
      "description": "Exactitud factual según la rúbrica, de 1 a 5"
    },
    "estado_veredicto": {
      "type": "string",
      "enum": [
        "ACEPTADO",
        "CORREGIR",
        "RECHAZADO"
      ]
    },
    "categoria_error": {
      "type": "string",
      "enum": [
        "NINGUNO",
        "DATO_INCORRECTO",
        "DATO_NO_RESPALDADO",
        "OMISION",
        "FORMATO_VOZ",
        "PROMESA_RIESGOSA",
        "FUERA_DE_AMBITO"
      ]
    },
    "critica": {
      "type": "string",
      "description": "Qué corregir, en una o dos frases"
    }
  },
  "required": [
    "exactitud_factual",
    "estado_veredicto",
    "categoria_error",
    "critica"
  ],
  "additionalProperties": false
}
```




Figura 6. Nodo "Esquema JSON del veredicto": Schema Type = Define using JSON Schema.

Campos: exactitud_factual (entero de 1 a 5) y estado_veredicto ("ACEPTADO" | "CORREGIR" | "RECHAZADO") son los dos que pide la consigna y los que evalúa el Switch. critica es la que se reenvía al agente en la ruta CORREGIR, y categoria_error alimenta el dashboard. El esquema tiene additionalProperties: false, así que el parser rechaza cualquier campo extra o cualquier valor fuera de los enum.

1.7 Branching y umbrales: nodo "Ruta del veredicto"




Figura 7. Switch en modo Rules. Izquierda: Regla 1 (ACEPTADO). Derecha: Regla 2 (CORREGIR) y Fallback Output = Extra Output renombrada RECHAZADO.

Salida	Condición	Qué hace
ACEPTADO	estado_veredicto = "ACEPTADO" Y exactitud_factual ≥ 4	Envía la respuesta a la salida real (texto ≤ 200 → ElevenLabs → audio por Telegram). El veredicto ya quedó registrado en Airtable.
CORREGIR (Self-Healing)	estado_veredicto $\neq$ "RECHAZADO" Y intento < 2 (incluye un ACEPTADO con exactitud menor a 4)	"Reintento con la crítica" reenvía la crítica del Juez al agente, que reescribe la respuesta. intento = \$runIndex de "Preparar evaluación", así que la vuelta máxima es la 3. ^a respuesta.
RECHAZADO (Human-in-the-loop)	Fallback: todo lo demás (RECHAZADO, reintentos agotados o falla del Juez)	Aviso al cliente ("Estamos verificando su consulta con un asesor") → Slack Send and Wait (Approval: Aprobar / Editar, espera máxima 4 h). Aprobar envía la respuesta por voz; Editar abre un formulario de texto libre y envía lo que escriba la persona por Telegram.

Protecciones contra los errores de la consigna: (1) el Juez no puede responder en texto libre: el parser fuerza el JSON y, si falla, la rama de error arma un RECHAZADO; (2) el loop de autocorrección tiene un límite (2 reintentos) y una salida humana obligatoria; (3) cada veredicto se registra en Airtable (Auditoria_QA), un repositorio externo a n8n, aunque la ejecución no se guarde.

1.8 Evidencia de las tres rutas en producción (Telegram, 10/10/2026)

Ejecución	Nota de voz (Whisper)	Recorrido	Resultado para el cliente
327	"¿A cuántos grados llevan la fruta?"	Juez: ACEPTADO, exactitud 5 → salida real	Audio: "entre 2 y 8 grados Celsius"
336	"Camión hasta Bariloche."	Intento 0: CORREGIR, 2, DATO_NO_RESPALDADO → reintento con la crítica → intento 1: ACEPTADO, 5	Audio: "No sé, le derivamos a un asesor." (corregido sin intervención humana)
333	"¿Cuánto tarda un camión hasta Bariloche?"	El Juez falló por el límite de tokens de Groq → veredicto de respaldo RECHAZADO (ERROR_JUEZ) → Slack → Aprobar	Aviso "en revisión" y audio después de la aprobación humana
Prueba controlada	"Envío a Villa Carlos Paz."	Juez: CORREGIR, 2, DATO_NO_RESPALDADO; con los reintentos deshabilitados temporalmente (Regla 2: intento < 0) → RECHAZADO → Slack → Editar	Aviso "en revisión" y texto escrito por el operador (texto de prueba)




Figura 8. Escalación en Slack (#operaciones): consulta, respuesta propuesta, exactitud 2/5, categoría DATO_NO_RESPALDADO, crítica del Juez y botones Editar / Aprobar.




Figura 9. Izquierda: salida del Juez en la ejecución 333 (falta del Juez → RECHAZADO, ERROR_JUEZ). Derecha: lo que vio el cliente en Telegram (avisos "en revisión", audios aprobados y la respuesta editada por el operador).




Figura 10. Causa de la falla del Juez en la ejecución 333: límite de 8.000 tokens por minuto del plan gratuito de Groq (3 reintentos agotados). El diseño la convirtió en una escalación humana, no en una respuesta sin control.

Registro de auditoría en Airtable (Auditoria_QA), filas del canal telegram:

Execution_I D	Intento	Veredicto	Exactitud	Categoría	Respuesta evaluada
327	0	ACEPTADO	5	NINGUNO	La fruta se transporta en rango refrigerado entre 2 y 8 grados Celsius.
333	0	RECHAZADO	1	ERROR_JUEZ	El plazo de entrega a Bariloche es entre 96 y 120 horas hábiles.
336	0	CORREGIR	2	DATO_NO_RESPALDADO	El plazo de entrega a Bariloche es entre 96 y 120 horas hábiles.
336	1	ACEPTADO	5	NINGUNO	No sé, le derivamos a un asesor.

1.9 Calibración del Juez

Antes del test A/B se comparó cada veredicto con la respuesta esperada de cada caso (revisión humana). El Juez se ajustó dos veces hasta coincidir en todos los casos:

Versión	Cambio en el prompt	Error observado	Coincidencia con revisión humana (A)
v1	Rúbrica base	Aceptó con 5 la inferencia "Bariloche → Patagonia" (falso negativo)	4/5
v2	"Todo dato debe aparecer escrito en los fragmentos"	Siguió aceptando Bariloche y castigó una cuenta correcta (0,8 % de 10 millones = 80.000) (falso positivo)	3/5
v3	Reglas separadas para lugares (solo si el nombre está escrito) y cálculos (una cuenta simple está respaldada), con un ejemplo de otra ciudad	Ninguno	5/5 en A y 5/5 en B (10/10)

2. Matriz de Datos A/B: 10 corridas

2.1 Diseño del experimento

	Arquitectura A (producción)	Arquitectura B (económica)
Modelo del agente	openai/gpt-oss-120b (Groq)	openai/gpt-oss-20b (Groq)
Precio Groq por millón de tokens	USD 0,15 de entrada / 0,60 de salida	USD 0,075 de entrada / 0,30 de salida
Constantes	Mismo System Prompt, misma herramienta RAG (Top-K 3, Min Score 0,68), mismo contexto de Airtable (Session_ID qa_test), mismas 5 preguntas y mismo Juez v3	Igual a la Arquitectura A: solo cambia el modelo del agente

Banco de pruebas: workflow "Checkpoint 8 - Test A/B (Juez)". Procesa un caso por vez con una pausa de 45 s, para respetar el límite de tokens de Groq, y registra cada veredicto en Airtable. Las 5 preguntas usan lenguaje informal e incluyen dos trampas: una localidad que no figura en el manual (C4) y un cálculo (C5).




Figura 11. Workflow del test A/B: Arquitectura bajo prueba → Buscar contexto (Airtable) → 5 casos → Un caso por vez → Agente bajo prueba → Preparar evaluación → Juez → Registrar veredicto (Airtable) → Pausa de 45 s.

2.2 Matriz de resultados

Arq.	Caso	Respuesta del agente	Exactitud	Veredicto del Juez	Revisión humana	Token s	Costo (USD)	Lat. (s)
A	C1	La fruta se transporta en el rango entre 2 y 8 grados Celsius.	5	ACEPTADO	Correcta	1.354	0,000264	1,45
A	C2	Sí, le cobran el cincuenta por ciento de la tarifa del viaje.	5	ACEPTADO	Correcta	1.263	0,000246	2,72
A	C3	Puede presentar reclamo, pero el plazo es 72 horas; al haber pasado 4 días, no está garantizada la indemnización. Lo derivamos a un asesor.	5	ACEPTADO	Correcta	1.448	0,000282	3,31
A	C4	El plazo de entrega a Bariloche es entre noventa y seis y ciento veinte horas hábiles.	2	CORREGIR · DATO_NO_RESPALDADO	Incorrecta: inferencia	1.369	0,000267	2,08
A	C5	El seguro adicional cuesta ochenta mil pesos.	5	ACEPTADO	Correcta	1.327	0,000259	2,43
B	C1	Entre 2 y 8 grados.	5	ACEPTADO	Correcta	1.338	0,000130	1,50
B	C2	No se cobra si cancela con más de 24 h; con menos de 24 h se cobra 50 % de la tarifa.	5	ACEPTADO	Correcta	1.274	0,000124	2,82
B	C3	No, el plazo es de 72 horas, por lo que no se garantiza indemnización.	3	CORREGIR · DATO_INCORRECTO	Incorrecta: niega un reclamo que el manual permite	1.427	0,000139	1,63

Arq.	Caso	Respuesta del agente	Exactitud	Veredicto del Juez	Revisión humana	Tokens	Costo (USD)	Lat. (s)
B	C4	El plazo de entrega a Bariloche es de 96 a 120 horas hábiles.	2	CORREGIR · DATO_NO_RESPALDADO	Incorrecta: inferencia	1.365	0,000133	1,55
B	C5	El seguro adicional cuesta 80.000 pesos.	5	ACEPTADO	Correcta	1.324	0,000129	2,48

Tokens y latencia: panel Logs de n8n (nodo "Agente bajo prueba", cada caso). Costo = tokens × precio de Groq, suponiendo 90 % de tokens de entrada (prompt + fragmentos) y 10 % de salida, porque las respuestas son cortas: USD 0,195 por millón en A y USD 0,0975 por millón en B. No incluye el Juez, que cuesta lo mismo en las dos arquitecturas (sección 3). Respuestas esperadas: C1 entre 2 y 8 °C; C2 50 % de la tarifa; C3 fuera de plazo pero se puede reclamar, sin garantía de indemnización; C4 "No sé" (Bariloche no figura); C5 USD 80.000 (0,8 %).

3. Dashboard y Proyección

3.1 Tablero consolidado

Métrica	A · gpt-oss-120b	B · gpt-oss-20b
Precisión media (exactitud del Juez, 1 a 5)	4,4	4,0
Tasa de aceptación del Juez	80 % (4/5)	60 % (3/5)
Respuestas correctas según revisión humana	4/5	3/5
Coincidencia Juez vs revisión humana	5/5	5/5
Tokens promedio del agente por corrida	1.352	1.346
Costo promedio del agente por corrida	USD 0,000264	USD 0,000131
Latencia media del agente	2,39 s	2,00 s
Estabilidad (fallas técnicas en las 5 corridas)	0	0
Costo del Juez por evaluación (1.883 tokens, gpt-oss-120b)	USD 0,000367	USD 0,000367

3.2 Categorías de error más frecuentes

Categoría	Casos	Dónde y por qué
DATO_NO_RESPALDADO	2 de 3 errores del A/B (67 %) + 2 en producción	Bariloche (A y B, 336) y Villa Carlos Paz: el agente ubica una ciudad en su provincia con conocimiento propio. Es un error del prompt del agente más que del modelo, porque lo cometen los dos.
DATO_INCORRECTO	1 de 3 errores del A/B (33 %)	B en C3: le dijo al cliente que no podía reclamar, cuando el manual permite hacerlo fuera de plazo, aunque sin garantía de indemnización.
ERROR_JUEZ (operativo)	1 en producción	Límite de tokens por minuto de Groq cuando el agente y el Juez usan el mismo modelo en una ráfaga de mensajes. El diseño lo derivó a un humano.

3.3 Costo proyectado a 1.000 ejecuciones

Concepto (USD cada 1.000 ejecuciones)	A · 120b	B · 20b
Agente (1.000 respuestas)	0,26	0,13
Juez (1.000 evaluaciones)	0,37	0,37
Reintentos por errores (20 % en A, 40 % en B: agente + Juez otra vez)	0,13	0,20
Costo de IA	0,76	0,70
Respuestas con error detectadas por el Juez	≈ 200	≈ 400
Casos que llegan a un humano (supuesto: 10 % de los errores no se autocorriges)	≈ 20	≈ 40
Costo humano (3 min de analista por caso, USD 8/h)	≈ 8,00	≈ 16,00
Costo total de operación	≈ 8,76	≈ 16,70

Supuestos: precios oficiales de Groq; 90/10 entrada/salida; tasa de error igual a la del test A/B; costo humano ilustrativo. Con 5 casos por arquitectura la diferencia de precisión es una señal, no una prueba estadística: se confirma con la auditoría mensual del registro de Airtable.

3.4 Recomendación comercial

Mantener la Arquitectura A (gpt-oss-120b) con el Juez activo. B ahorra unos 6 centavos de dólar de IA cada 1.000 consultas, pero duplica las respuestas erróneas. Cada error extra cuesta un reintento y, cuando no se autocorriga, minutos de un analista, así que el costo total de B es casi el doble. Además, el error típico de B (C3) le niega al cliente un derecho que el manual le da, que es un riesgo comercial y de reputación que no se compensa con el ahorro.

- **Siguiente mejora (M9):** agregar al prompt del agente la regla de localidades que hoy solo tiene el Juez. Ataca la categoría de error más frecuente y reduce reintentos en las dos arquitecturas.
- **Estabilidad:** para producción, pasar a Groq Dev Tier o mover el Juez a un modelo con cupo propio, para que el agente y el Juez no compitan por los mismos 8.000 tokens por minuto.