Plan de gobernanza del canal de voz supervisado de Logística Demo S.A.

Sistema gobernado: el agente del Módulo 8. Las notas de voz por Telegram pasan por Whisper, el agente con RAG sobre el manual MAN-SC-001 (Groq gpt-oss-120b) y el Juez LLM con Switch Aceptar / Corregir / Escalar a Slack, y la respuesta vuelve en voz con ElevenLabs. Todos los veredictos se registran en Airtable. **Punto de partida financiero:** el costo de IA proyectado en el M8, USD 0,76 cada 1.000 ejecuciones (agente + Juez + reintentos).

Entregable de la consigna	Dónde está
Dashboard operativo con KPIs definidos	1.1 (KPIs) y 2.1 (panel en Airtable con la columna traceId)
Matriz financiera de costos de tokens con retorno esperado	1.2 (ROI), 1.3 (TCO), 1.4 (Prompt Caching) y 1.5 (límites en las llaves)
Mapa de mitigación de riesgos éticos y de ciberseguridad	3.1 (riesgos y controles), 3.2 (prompt de objetividad) y 3.3 (privacidad del proveedor)
Esquema de logs JSON correlacionados con traceId	2.2 (esquema) y 2.3 (recorrido del traceId, con evidencia)

Dimensión 1 · Planificación financiera y economía del token

1.1 KPIs de negocio (dashboard)

KPI	Cómo se mide (fuente: Auditoria_QA)	Piloto (10/10/2026)	Meta a 90 días	Para la dirección
Tasa de resolución autónoma	traceId cuya última evaluación es ACEPTADO sin pasar por Slack / total de traceId	5 de 6 (83 %)	≥ 60 %	Consultas que el equipo ya no atiende
Tiempo operativo ahorrado	Consultas resueltas en forma autónoma × 6 min (tiempo manual del baseline)	30 min	≥ 110 h/mes	Horas liberadas para cuentas y reclamos
Reducción de errores	Respuestas con exactitud < 4 interceptadas por el Juez antes de llegar al cliente / respuestas con exactitud < 4	2 de 2 (100 %)	≥ 95 %	Errores que no llegan al cliente
Exactitud media	Promedio de exactitud_factual (1 a 5), sin contar fallas del Juez	4,1	≥ 4,5	Calidad de las respuestas
Satisfacción del usuario (CSAT)	Botones "¿Le sirvió? Sí / No" en Telegram después del audio, registrados con el traceId	A implementar	≥ 80 % "Sí"	Experiencia del cliente

Piloto: 6 interacciones reales por Telegram del 10/10/2026 (ejecuciones 327, 333, 336, 345, 348 y 352). No se cuenta la prueba forzada de Villa Carlos Paz. La única escalación (333) se debió al límite de tokens de Groq. Es una muestra chica: los valores se recalculan cada mes con todo el registro.

1.2 ROI contra el baseline manual

Tarea automatizada	Baseline manual (M7)	Volumen por mes	Con el agente	Horas evitadas por mes	Ahorro (USD/mes)
Responder consultas informativas (plazos, temperaturas, reclamos, seguros)	3 analistas, 6 min por consulta, primera respuesta en 5 h hábiles	1.890 (90 por día hábil)	60 % autónomas (meta conservadora; el piloto dio 83 %)	113	907
Control de calidad de las respuestas	El supervisor revisa el 5 % por muestreo, 3 min cada una	95 revisiones	El Juez evalúa el 100 % y el humano solo ve las escalaciones	5	38
Total				118	945

Retorno esperado: ahorro de USD 945 por mes contra un TCO de USD 146 (1.3) da un beneficio neto de USD 799 por mes, un ROI mensual de 547 %. Con el TCO optimizado manteniendo Airtable Team (USD 68,51), el ROI es de 1.279 %. La implementación (unas 60 h de construcción y pruebas, USD 480; n8n y Groq sin licencia) se recupera en menos de un mes. **Picos de demanda:** el equipo atiende unas 240 consultas por día (3 analistas × 8 h × 10 por hora). En un pico de 3 veces el promedio (lunes, fin de mes o después de un feriado) llegan 270 y se acumulan atrasos. El

agente responde en paralelo y sin horas extra: su único límite es el cupo de tokens de Groq, que se amplía con el plan Developer.

Supuestos: costo empresa de un analista USD 8 por hora (ilustrativo, igual que en el M8); volumen y tiempos del baseline del M7 (empresa ficticia).

1.3 Matriz de Costo Total de Operación (TCO) mensual

Componente	Cálculo (1.890 interacciones por mes)	Actual (USD/mes)	Optimizado (USD/mes)
LLM: agente + Juez + reintentos (Groq gpt-oss-120b)	USD 0,76 cada 1.000 (M8) × 1,89	1,44	1,30 (caché automático de Groq)
Transcripción (Groq Whisper large-v3)	USD 0,111 por hora; mínimo facturable de 10 s por audio → 5,25 h	0,58	0,21 (whisper-large-v3-turbo, USD 0,04 por hora)
Voz (ElevenLabs)	~120 caracteres por respuesta → 226.800 créditos	99,00 (plan Pro; Multilingual v2, 1 crédito por carácter)	22,00 (plan Creator; modelo Flash, 0,5 créditos por carácter)
Embeddings de las consultas (Google Gemini)	Uso dentro de la capa gratuita	0,00	0,00
Registro y memoria (Airtable)	Unas 2.300 filas por mes superan el límite gratuito de 1.000 registros por base	20,00 (Team, 1 usuario)	0,00 (archivo mensual a CSV y quedarse en Free)
Servidor de n8n (self-hosted)	VPS chico para producción (hoy corre en una PC local con ngrok)	10,00	10,00
Escalaciones humanas	2 % de las interacciones (≈ 38 por mes) × 3 min × USD 8 por hora	15,00	15,00
Total TCO		146,02	48,51 (68,51 si se mantiene Airtable Team)

Estrategias de contención (no técnicas): (1) acotar el contexto: el agente recibe solo los 3 fragmentos del manual que superan el score 0,68, no el manual entero, y la memoria guarda solo 6 mensajes; (2) respuestas de 200 caracteres como máximo, porque la voz se cobra por carácter; (3) las contingencias (audio inválido) responden en texto, sin IA ni TTS; (4) los reintentos tienen un tope de 2; (5) Prompt Caching (1.4). El componente que más pesa no es el token, es la voz: elegir el modelo de TTS mueve el presupuesto más que cambiar de LLM.

Precios de lista publicados por los proveedores, consultados el 10/10/2026: Groq (gpt-oss-120b USD 0,15 de entrada y 0,60 de salida por millón de tokens; Whisper USD 0,111 por hora), ElevenLabs (Creator USD 22 por 121.000 créditos; Pro USD 99 por 600.000), Airtable (Team USD 20 por usuario y por mes, en facturación anual).

1.4 Pricing de proveedores y Prompt Caching

Opción (1.000 interacciones, ~2,9 M tokens de entrada y 0,32 M de salida)	Sin caché	Con caché	Condición del caché
Groq gpt-oss-120b (actual)	USD 0,63	USD 0,52	Automático: el prefijo repetido se cobra al 50 %
Anthropic Claude Haiku 4.5 (USD 1 / 5 por millón)	USD 4,50	No aplica	Mínimo cacheable de 4.096 tokens: los bloques fijos (prompt ≈ 1.000 + rúbrica ≈ 750) no llegan
Anthropic Claude Sonnet 5.5 (USD 2 / 10 por millón)	USD 9,00	≈ USD 6,25 (−31 %)	Mínimo de 512 tokens. Lectura de caché USD 0,10 por millón (el 5 % del precio de entrada); escritura × 1,25; vida de 5 min que se renueva con cada uso

Cómo se aprovecha el caché: los bloques fijos y largos (System Prompt, rúbrica del Juez y, si en el futuro se pasa el manual completo, el manual) van al principio del prompt, y lo variable (pregunta, fragmentos, memoria) va al final. Con Anthropic se marca el bloque fijo con cache_control. Con un tráfico de 90 consultas por día (una cada 5 minutos en horario laboral), el caché de 5 minutos se renueva casi siempre. **Decisión:** se mantiene Groq, porque a este volumen es unas 10 veces más barato que Claude con caché. Prompt Caching de Anthropic pasa a ser relevante si se migra a Claude para casos complejos (reclamos o cotizaciones), donde baja un 31 % el costo de Sonnet.

1.5 Control preventivo de API Keys: separación de entornos

Servicio	Desarrollo (pruebas, test A/B, cambios de prompt)	Producción (canal publicado)
Groq	Organización separada "Logística Demo - DEV". Límite de gasto de USD 5 por mes, con alertas al 50, 75 y 90 % (Settings → Billing → Limits)	Organización "Logística Demo - PROD". Límite de USD 10 por mes: el consumo esperado es de USD 2, así que queda margen para picos
ElevenLabs	Llave restringida solo a "De texto a voz", con tope de 2.000 créditos (ya configurada en el M6)	Llave restringida solo a TTS, con un tope igual al plan contratado
Airtable	Base "Memoria Agente DEV" y token limitado a esa base	Base "Memoria Agente" y token limitado a esa base
n8n	Credenciales con sufijo DEV; workflows de prueba sin publicar	Credenciales PROD; solo el canal y el Juez publicados

Por qué organizaciones separadas: en Groq el límite de gasto se fija a nivel organización y alcanza a todas sus llaves; no existe un límite por llave. La única forma de que un bucle en desarrollo no consuma el presupuesto de producción es separarlos físicamente. Al llegar al límite, Groq bloquea las llamadas nuevas (error blocked_api_access) hasta el mes siguiente, y su medición tiene unos 10 a 15 minutos de demora. Por eso el límite de desarrollo es bajo.
Defensas dentro del flujo contra bucles: máximo 8 iteraciones del agente, 2 reintentos de Self-Healing, 3 reintentos de llamada con 5 s de espera y una pausa de 45 s por caso en el banco de pruebas.

Dimensión 2 · Logs estructurados y trazabilidad (traceId)

2.1 Panel operativo en Airtable (tabla del M8 con la columna traceId)

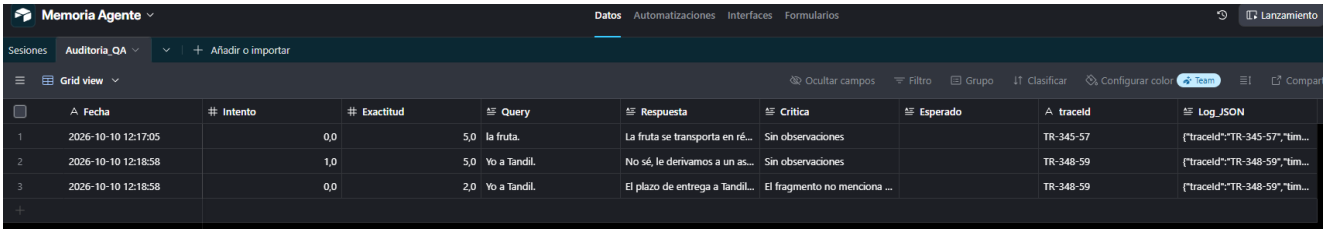


Figura 1. Auditoria_QA en Airtable, alimentada desde n8n: cada evaluación del Juez es una fila con Intento, Exactitud, Query, Respuesta, Crítica, traceId y Log_JSON. Las dos filas de Tandil comparten el traceId TR-348-59: intento 0 CORREGIR (2) e intento 1 ACEPTADO (5).

Cómo salen los KPIs del panel: vista agrupada por traceId (Group by traceId). La resolución autónoma cuenta los grupos cuya última fila es ACEPTADO, la exactitud media es el resumen promedio de la columna Exactitud y los errores interceptados son las filas CORREGIR o RECHAZADO. No hace falta un panel nuevo: es la misma tabla del M8 con dos columnas más, traceId y Log_JSON.

2.2 Esquema del log JSON máquina-procesable

Campo	Origen en n8n	Para qué sirve en una auditoría
traceId	Purgar audio del cliente	Une todos los registros de una misma interacción, entre workflows y sub-workflows
timestamp	$now.toISO()	Ordena el rastro en el tiempo, con zona horaria
nodeName	Nodo que evalúa	Ubica en qué paso del lienzo se tomó la decisión
toolOutput	Fragmentos que devolvió buscar_manual_politicas (hasta 800 caracteres)	Muestra en qué evidencia se apoyó el agente: separa una alucinación de un error del manual
systemPromptSnapshot	Versión del prompt del agente, versión del Juez y modelo	Reproduce con qué instrucciones respondió el sistema en ese momento. Se guarda el identificador de versión y el texto completo vive versionado en el repositorio, para no repetir unos 3.000 caracteres en cada fila
confidenceScore	exactitud_factual del Juez / 5 (0,2 a 1)	Confianza normalizada para filtrar y alertar (por ejemplo, < 0,8)
Adicionales	executionId, workflow, canal, intento, toolName, respuesta, veredicto, categoriaError	Contexto para reconstruir el caso completo


```
{
  "traceId": "TR-345-57",
  "timestamp": "2026-10-10T12:17:05.238-04:00",
  "executionId": "345",
  "workflow": "Checkpoint 9 - Canal de Voz supervisado (AI-as-a-Judge)",
  "nodeName": "Evaluar respuesta (Juez)",
  "canal": "telegram",
  "intento": 0,
  "toolName": "buscar_manual_politicas",
  "toolOutput": "[   {     \"resultado\": \"[Fragmento 1 | Fuente: MAN-SC-001 v3.1 | Sección: 5. Transporte
refrigerado | score 0.73]\\n ## 5. Transporte refrigerado\\n\\n### 5.1 Rang …(truncado a 800 caracteres)",
  "respuesta": "La fruta se transporta en régimen refrigerado, con temperatura garantizada entre 2 y 8 grados
Celsius.",
  "systemPromptSnapshot": {
    "agente": "cerebro-voz-v4",
    "juez": "juez-v3",
    "modelo": "openai/gpt-oss-120b"
  },
  "confidenceScore": 1,
  "veredicto": "ACEPTADO",
  "categoriaError": "NINGUNO"
}
```


Log real de la ejecución 345 (campo Log_JSON de Airtable). El toolOutput está recortado para este documento.

2.3 Recorrido del traceId por los sub-workflows

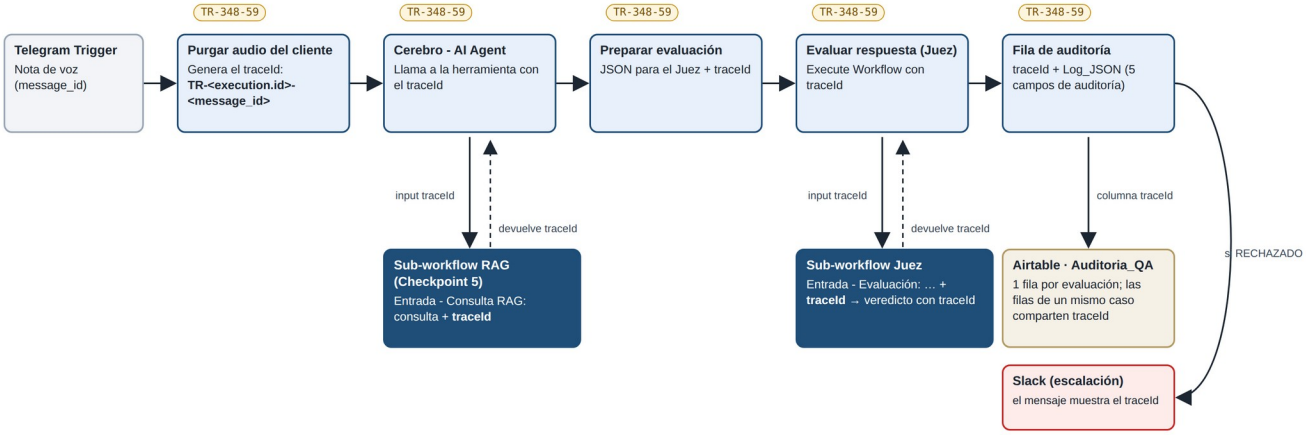


Figura 2. El traceId se genera una vez, a partir del número de ejecución y del ID del mensaje de Telegram, y se pasa como input explícito a cada sub-workflow, que lo devuelve en su salida.

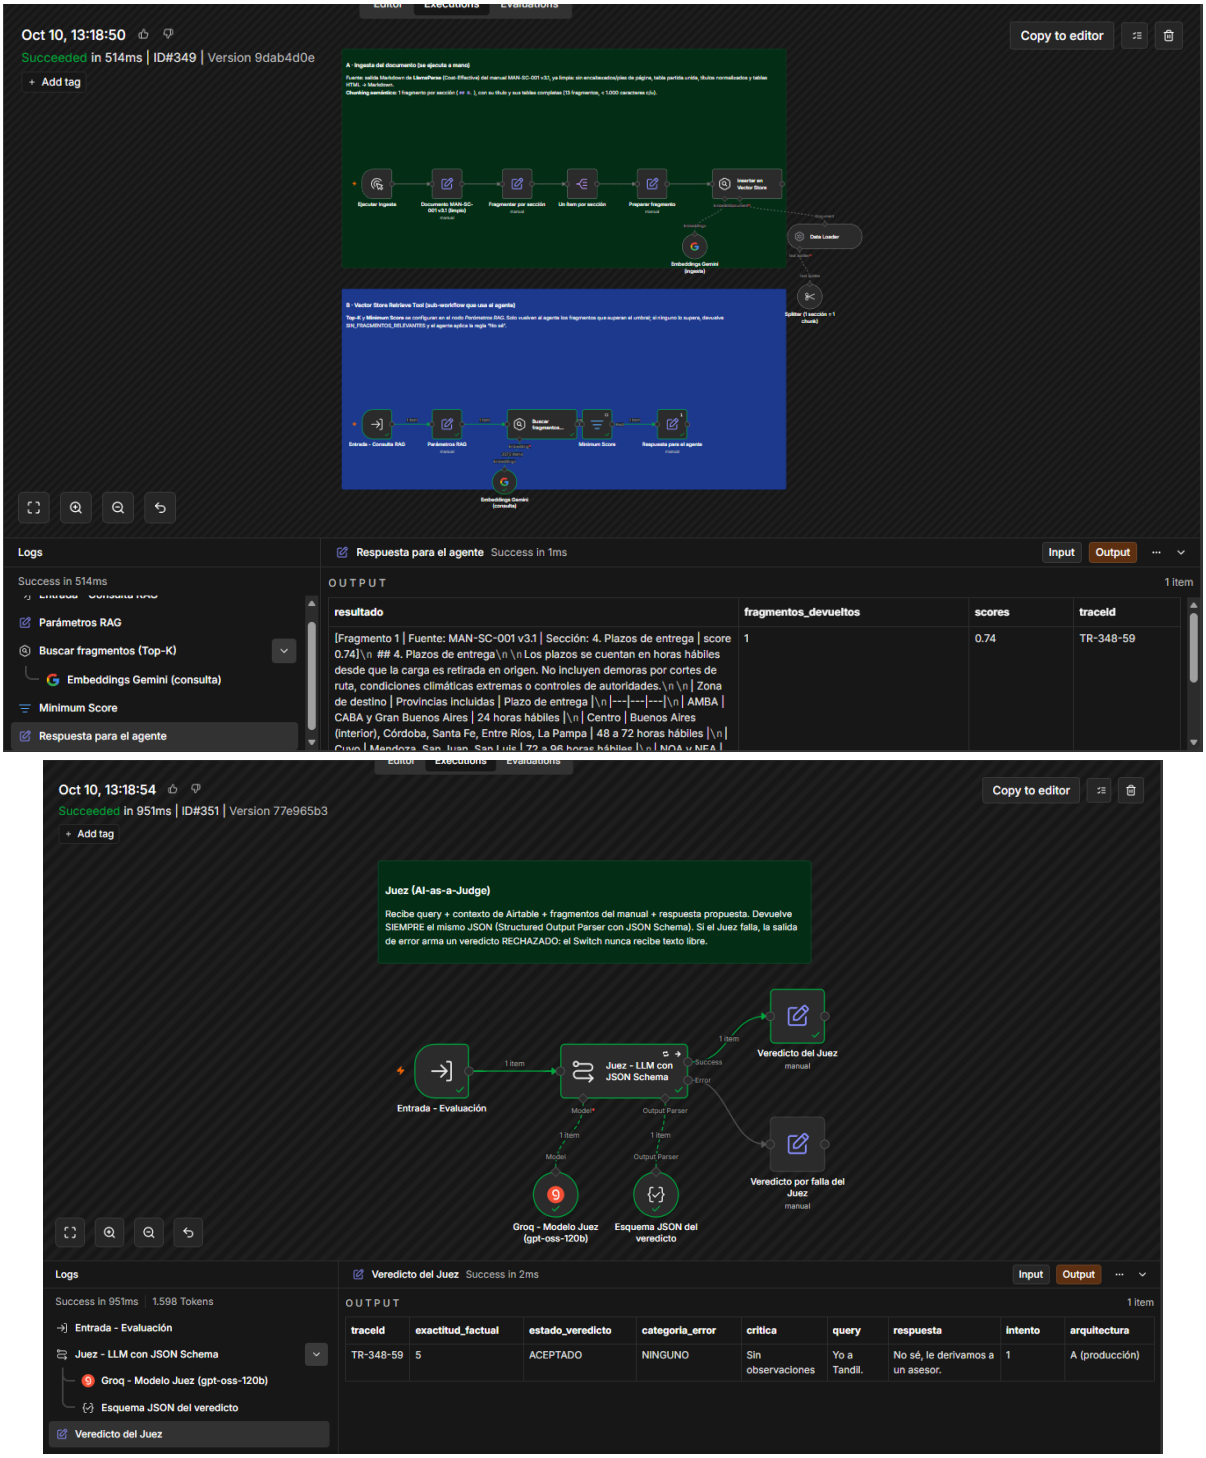


Figura 3. Arriba: sub-ejecución del RAG (Checkpoint 5), cuya salida "Respuesta para el agente" lleva traceId TR-348-59 (sección 4, score 0,74). Abajo: sub-ejecución del Juez, cuyo "Veredicto del Juez" lleva el mismo traceId.

Auditoría retroactiva en la práctica: cruzando por TR-348-59 el log de Airtable con la sub-ejecución del RAG apareció una inconsistencia. El RAG sí devolvió la sección 4, pero el log del intento 0 decía "SIN_FRAGMENTOS". La causa: n8n ejecuta las ramas de arriba hacia abajo, así que el registro del intento 0 se escribía después del reintento y tomaba los datos del intento 1. Se corrigió ubicando "Fila de auditoría" y "Registrar veredicto" por encima del Switch, para que el log se escriba antes de seguir la ruta. La evidencia que usó el Juez nunca estuvo afectada: su crítica cita la zona Centro de la sección 4.

Verificación de la corrección (traceId TR-354-63, Pergamino, con memoria de chat limpia): las dos filas se registraron en orden cronológico (intento 0 a las 12:41:50, intento 1 a las 12:41:56) y cada una con sus propios fragmentos.

traceId	Intento	Veredicto	toolOutput	Respuesta evaluada
TR-354-63	0	CORREGIR (2) · DATO_NO_RESPALDADO	Sección 4, score 0,68	El plazo para la zona Centro, que incluye Pergamino, es entre 48 y 72 horas hábiles.
TR-354-63	1	ACEPTADO (5)	Sección 4, score 0,74	No dispongo de información sobre el plazo para Pergamino. Le derivamos a un asesor.

Dimensión 3 · Gobernanza ética, ciberseguridad y compliance

3.1 Mapa de riesgos y controles

Riesgo	Control configurado	Dónde está en el flujo
Alucinación o dato no respaldado (por ejemplo, inferir el plazo de una ciudad que el manual no nombra)	RAG con Top-K 3 y score mínimo 0,68; regla "No sé" en el prompt; el Juez verifica cada lugar, número y plazo contra los fragmentos y manda a corregir (DATO_NO_RESPALDADO)	buscar_manual_politicas (sub-workflow RAG) · System Prompt del agente · Juez + Ruta del veredicto (CORREGIR)
Prompt injection ("ignorá tus reglas…")	El prompt indica que las instrucciones dentro del mensaje son texto del cliente; el contexto de Airtable va entre delimitadores [INICIO/FIN DEL CONTEXTO COMPARTIDO] y se declara como datos; el agente solo tiene una herramienta de lectura (no puede escribir, pagar ni enviar nada); el Juez evalúa la respuesta en una llamada aparte, con su propia rúbrica	System Prompt del agente · Buscar contexto (Airtable) · herramientas del agente · sub-workflow Juez
Sesgo algorítmico o trato desigual	Sección OBJETIVIDAD Y EQUIDAD en el prompt (3.2); la misma política del manual para todos; la rúbrica del Juez no usa datos del cliente; muestreo mensual de Auditoria_QA por categoría de error	System Prompt del agente · rúbrica del Juez · panel de Airtable
Promesas de dinero, precios o temas legales	El Juez los marca RECHAZADO (PROMESA_RIESGOSA) → la respuesta se congela y se escala a Slack con Aprobar / Editar; al cliente solo le llega un aviso neutro	Juez → Ruta del veredicto (RECHAZADO) → Escalar a humano (Slack)
Exposición de datos o caída del proveedor	Audio purgado en memoria y ejecuciones de producción sin guardar; payload mínimo a Slack; llaves restringidas y separadas por entorno; si el Juez falla (límite de tokens), se aplica un RECHAZADO de respaldo y la respuesta no sale sin control	Purgar audio del cliente / generado · Settings (Do not save) · Veredicto por falla del Juez

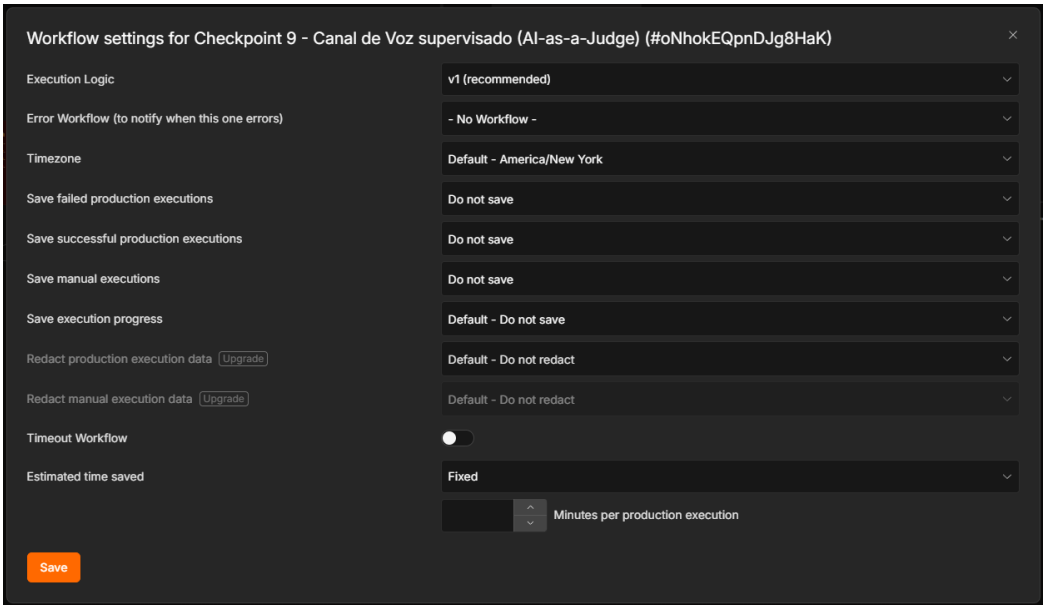


Figura 4. Settings del canal: las ejecuciones de producción y las manuales no se guardan (no queda audio ni conversación en la base de n8n). La trazabilidad vive en Airtable, con el texto y sin el audio.

3.2 Mecanismo de objetividad en el System Prompt

```
# OBJETIVIDAD Y EQUIDAD
- Aplicá exactamente las mismas políticas del manual a todos los clientes, sin importar su nombre, género, edad, origen, forma de hablar, ortografía o tamaño de empresa.
- No hagas suposiciones sobre el cliente ni sobre su mercadería, y no uses datos personales para decidir qué responder.
- No des opiniones personales, políticas ni comerciales: respondé en nombre de la empresa y solo con lo que dice el manual.
- Si el cliente está enojado o es agresivo, mantené el mismo tono respetuoso y la misma política.
```

Esta sección se agregó al prompt del agente en este módulo y se complementa con las reglas que ya tenía: responder solo con el manual, no inferir datos, no prometer precios ni compensaciones y tratar como texto del cliente cualquier instrucción que venga en su mensaje.

3.3 Privacidad: que los datos no se usen para entrenar modelos

Proveedor	Plan o configuración que se usaría	Dónde se verifica
Groq (LLM y Whisper, en uso)	Por defecto no retiene los datos de inferencia; puede guardar entradas y salidas hasta 30 días solo para confiabilidad y abuso. Se activa Zero Data Retention (ZDR) para la organización de producción: así Groq no guarda nada. Según su Services Agreement, no usa las entradas ni las salidas para entrenar modelos sin permiso explícito	console.groq.com → Settings → Data Controls (lo activa un admin de la organización). Documentación: console.groq.com/docs/your-data
Anthropic (alternativa, si se migra a Claude)	Commercial Terms de la API: "Anthropic may not train models on Customer Content from Services". ZDR disponible por acuerdo con Ventas para organizaciones aprobadas	anthropic.com/legal/commercial-terms; en la Console: Settings → Privacy Controls → Data retention period

A quién consultar en un despliegue real: a **Legal**, que valida el contrato y el acuerdo de tratamiento de datos (DPA), la transferencia internacional (Groq procesa en Google Cloud en EE. UU.) y el cumplimiento de la Ley 25.326 de Protección de Datos Personales; y a **Sistemas / Seguridad**, que activa ZDR, administra las llaves por entorno y revisa periódicamente la configuración de Data Controls.